Propuesta Técnica

Plataforma de Datos CaféNorte

Arquitectura AWS · Estimación de Costos · Plan de Implementación

Preparado por: Tuxpas · AWS Advanced Partner

Fecha: Abril 2026 · Versión 1.0

Confidencial — Solo para uso interno de CaféNorte

Índice de Contenido

1.	Contexto y Problema del Cliente	3
2.	Arquitectura Propuesta en AWS	3
3.	Estimación de Costo Mensual	5
4.	Plan de Implementación por Fases	6
5.	Supuestos y Preguntas Abiertas	8

1. Contexto y Problema del Cliente

CaféNorte es una cadena retail mexicana con 40 tiendas físicas distribuidas entre CDMX, Bajío, Monterrey, Guadalajara y la franja fronteriza norte (Tijuana, Mexicali, Ciudad Juárez). Además de su canal físico, opera una tienda Shopify que vende a México, EE.UU. y Europa.

> **El problema**
>
> "Tenemos datos en tres lugares distintos y cada área reporta un número diferente. El dueño quiere un solo lugar donde ver ventas y rotación de inventario de todas las tiendas. Tenemos presupuesto en AWS pero no mucho — alrededor de USD $200 al mes en infraestructura de datos."

Fuentes de datos actuales

Archivo	Sistema origen	Formato	Volumen
sales.csv	POS tiendas físicas	CSV	86,490 filas
inventory.json	ERP legacy	JSON anidado	230,776 snapshots
ecommerce_orders.parquet	Shopify	Parquet	9,947 órdenes

2. Arquitectura Propuesta en AWS

La arquitectura propuesta es 100% serverless y managed — sin servidores que administrar, pagando solo por lo que se llega a usar. Está diseñada para operar dentro del presupuesto de $200 USD/mes con un amplio margen para poder crecer o añadir.

Diagrama de Arquitectura

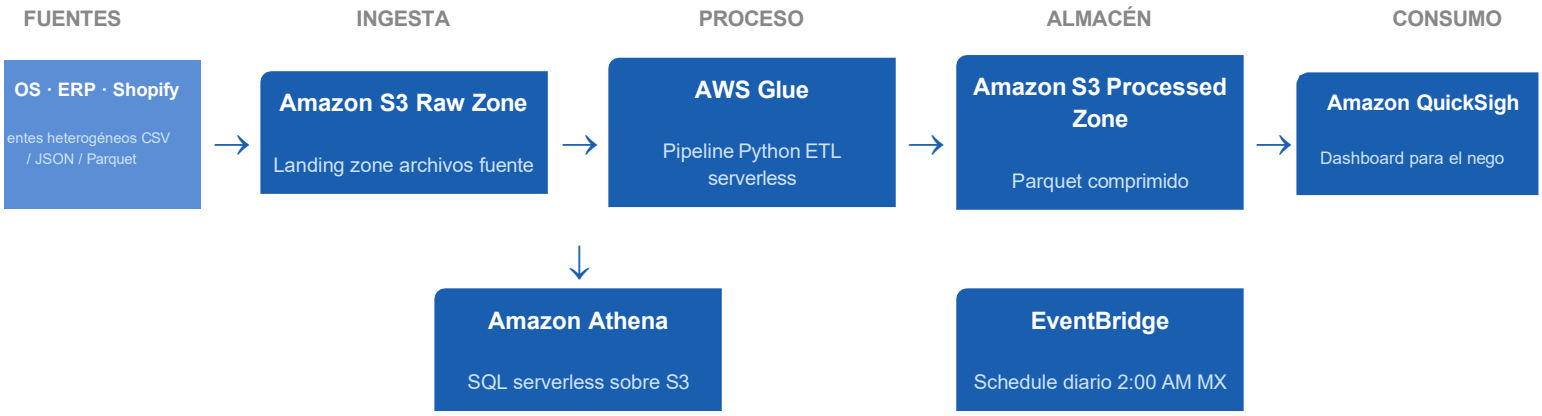

Figura 1 — Arquitectura de datos CaféNorte en AWS (stack serverless)

Justificación de servicios

Amazon S3	Almacenamiento de objetos estándar. Recibe los archivos fuente en zona raw y guarda los Parquet procesados. Durable (11 noves), barato ($0.023/GB/mes) y nativo para todos los servicios AWS de datos.
AWS Glue	Servicio ETL serverless que ejecuta el pipeline Python. No requiere servidores, escala automáticamente y se paga por minuto de ejecución. Ideal para el volumen de CaféNorte (~330k filas).
Amazon Athena	Motor de queries SQL serverless sobre los Parquet en S3. Permite que el equipo de TI haga consultas ad-hoc sin base de datos que administrar. Cobra $5/TB escaneado — con Parquet comprimido el costo es mínimo.
Amazon EventBridge	Orquestador de eventos que dispara el pipeline Glue según un schedule. Gratis para el volumen de CaféNorte. Reemplaza la necesidad de un servidor de cron jobs.
Amazon QuickSight	Herramienta de BI nativa de AWS. Se conecta directamente a Athena. $25/autor/mes + $5/usuario-Reader/mes modo Standard. El dueño y el director de TI tendrían acceso a un dashboard actualizado.

3. Estimación de Costo Mensual

La estimación asume ejecución diaria del pipeline (una vez por noche), 2 usuarios en QuickSight y la región us-east-1 (Norte de Virginia) como base de operación. Los precios son referencia de AWS Pricing Calculator a abril 2026.

Servicio	Supuesto de uso	Costo/mes
Amazon S3	~75 MB almacenados (raw + processed). Crece ~5 MB/mes.	$0.01
AWS Glue	5 min / ejecución × 1 DPU × 30 días = 2.5 DPU-hora.	$1.10
Amazon Athena	~500 queries/mes × 5 MB escaneados (Parquet comprimido) = 2.5 GB.	$1.00 – $5.00
EventBridge	30 eventos/mes. Dentro del nivel gratuito (1M eventos/mes).	$0.00
Amazon QuickSight	1 usuarios Reader $5 + $25/autor/mes (plan Standard).	$30.00
TOTAL ESTIMADO	**Muy por debajo del límite de $200 USD/mes**	**~$32/mes**

Headroom disponible: ~$166/mes

El costo estimado de $32/mes deja $166 de margen dentro del presupuesto de $200. Esto permite agregar hasta 15 usuarios adicionales en QuickSight, incorporar nuevas fuentes de datos, o activar alertas vía SNS sin cambiar la arquitectura.

Nota: Si CaféNorte tiene requerimientos regulatorios de que los datos permanezcan en México, la región mx-central-1 (Querétaro) está disponible en AWS aunque algunos servicios pueden tener un costo ligeramente mayor (~10-15% adicional). El impacto en el total mensual sería menor a $3.

4. Plan de Implementación por Fases

El plan está diseñado para entregar valor incremental desde la primera semana. El cliente tendrá datos consolidados en AWS antes de que termine la Fase 1, y un dashboard funcional al finalizar la Fase 2.

FASE 1 — Fundación — Datos en un solo lugar

Semanas 1–2

Objetivo: *Centralizar las fuentes de datos en AWS y dejar una primera versión consultable del modelo analítico*

- Crear bucket S3 con estructura raw/, processed/, results/
- Subir las 4 fuentes de datos a la zona raw
- Migrar el pipeline Python a AWS Glue (el código ya existe, solo se empaqueta)
- Validar que el output en S3 coincide con los resultados locales
- Configurar EventBridge para ejecutar el pipeline diariamente a las 2:00 AM

Entregable: Pipeline corriendo en AWS, datos actualizados cada mañana en S3.

Riesgo: *El ERP legacy genera inventory.json manualmente. Hay que definir con TI cómo ese archivo llega a S3 automáticamente antes de cerrar la fase.*

FASE 2 — Dashboard — El dueño ve los datos

Semanas 3–4

Objetivo: *Entregar al cliente una primera versión funcional del dashboard con las métricas principales solicitadas.*

- Configurar Glue Data Catalog para que Athena reconozca los Parquet como tablas
- Crear las 4 queries de negocio como Athena Named Queries
- Configurar QuickSight conectado a Athena
- Construir dashboard con rotación, quiebres de stock, MoM y margen por tienda
- Capacitación al dueño y director de TI (1 sesión de 2 horas)

Entregable: Dashboard accesible desde el browser con datos frescos cada mañana.

Riesgo: *QuickSight tiene curva de aprendizaje. Si el equipo prefiere algo más familiar, Metabase es una alternativa open source (~$10/mes adicional en EC2).*

FASE 3 — Automatización — Cero intervención manual

Semanas 5–8

Objetivo: *Convertir el MVP en una solución operable diariamente con controles básicos de calidad y costo.*

- Conectar el POS directamente a S3 vía exportación automática o API
- Configurar exportación de Shopify a S3 vía API nativa o Lambda
- Automatizar la entrega del ERP legacy a S3 vía script en el servidor
- Agregar alertas con SNS si el pipeline falla o alguna fuente no llega a tiempo

Entregable: Pipeline 100% autónomo con alertas al equipo de TI.

Riesgo: *El ERP legacy es la mayor incógnita. Si no permite exportación automática, puede requerir un desarrollo custom con costo adicional de tiempo.*

FASE 4 — Evolución — Más valor de los datos

Mes 3 en adelante

Objetivo: Documentar decisiones, supuestos y límites del MVP para que el cliente pueda operar y extender la plataforma.

- Agregar nuevas preguntas de negocio según el uso real del dashboard
- Evaluar migración a Redshift Serverless si el volumen justifica queries más complejas
- Explorar forecasting de demanda con SageMaker Canvas (ML sin código)
- Incorporar nuevas fuentes de datos: CRM, datos de clima, competencia

Entregable: Plataforma de datos madura que crece con el negocio.

Riesgo: *El scope de la Fase 4 depende del apetito de inversión del cliente y de lo que el equipo de TI pueda absorber operativamente.*

5. Supuestos y Preguntas Abiertas

Esta propuesta se basa en los datos y el contexto compartidos en la primera reunión. Los siguientes supuestos y preguntas deberán validarse antes de firmar el acuerdo de implementación.

Supuestos tomados para esta propuesta

- El inventario físico del ERP abastece también los pedidos de Shopify (stock compartido entre canales).
- El tipo de comprobante 'E' en el POS sigue la nomenclatura CFDI del SAT (egreso = devolución o nota de crédito).
- Los datos actuales son representativos del volumen futuro — sin expansión agresiva de tiendas en el corto plazo.
- 2 usuarios consumirán el dashboard en QuickSight (dueño + director de TI).
- La región AWS us-east-1 (Norte de Virginia) es aceptable. Si hay requerimientos de residencia de datos en México, se usaría mx-central-1 con un impacto menor a $3/mes adicional.
- El equipo de TI puede operar Glue y S3 con capacitación básica (incluida en la Fase 2).

Sobre las fuentes de datos

1. ¿El inventory.json se genera manualmente hoy o existe algún proceso automático en el ERP? ¿Con qué frecuencia se actualiza?
2. ¿El POS tiene API o exportación automática, o los archivos CSV se generan manualmente?
3. ¿Hay más fuentes de datos que no están en el zip — por ejemplo CRM, datos de nómina, o sistema de reservas?
4. ¿Los 6 product_handles de Shopify sin mapeo en el ERP son productos descontinuados o activos? ¿Por qué no están en el catálogo del ERP?

Sobre el negocio

1. ¿El inventario físico del ERP es el mismo stock que surte los pedidos de Shopify, o tienen bodegas separadas para cada canal?
2. ¿El precio de venta es uniforme en todas las tiendas o hay precios diferenciados por región? — Se encontraron SKUs con precio significativamente menor al promedio nacional en ciertas tiendas.
3. ¿Qué explica que CN-00015 Especial Cafe Molido y CN-00002 Sándwich Comida Caliente se vendan por debajo del costo en las 40 tiendas? ¿Hubo un cambio de proveedor reciente sin actualización de lista de precios?
4. ¿Cuáles son las métricas que el dueño revisa hoy manualmente? ¿Hay KPIs adicionales que quiera ver en el dashboard más allá de las 4 preguntas del análisis inicial?

Sobre infraestructura y seguridad

1. ¿La cuenta AWS ya tiene configuraciones de VPC, IAM o políticas de seguridad que debamos respetar?
2. ¿Cuánto tiempo deben retenerse los datos por requerimientos de cumplimiento o auditoría?
3. ¿Quién en el equipo de TI será el administrador del pipeline en producción? ¿Tiene experiencia previa con AWS?
4. ¿Los datos de clientes de Shopify (nombre, email, RFC) tienen requerimientos de privacidad bajo la Ley Federal de Protección de Datos Personales?

Sobre el proyecto

1. ¿Hay una fecha límite específica para tener el dashboard operativo?
2. ¿El presupuesto de $200 USD/mes es fijo o es un punto de partida negociable si el valor lo justifica?
3. ¿Quién aprueba los cambios en producción — el director de TI, el dueño, o ambos necesitan aprobar?

Estamos listos para iniciar la Fase 1 en cuanto se validen estos puntos. El siguiente paso es una sesión de 1 hora con el director de TI para revisar el acceso a la cuenta AWS y definir el mecanismo de entrega de las fuentes de datos.